Ollama

- Ollama는 사용자가 자신의 PC에서 대규모 언어 모델(LLM)을 직접 실행할 수 있도록 도와주는 오픈소스 플랫폼입니다.
- 다양한 오픈 소스 LLM 모델의 설치, 실행, 커스터마이즈 기능까지 간편하게 제공하기 때문에 오픈 소스 AI 기술을 활용하고자 하는 사용자들에게 최적의 솔루션을 제공합니다.

Ollama 장점

- Ollama의 가장 큰 강점은 로컬 환경에서의 모델 구동에 있습니다. 이는 다음과 같은 세 가지 핵심적인 이점을 제공합니다:
  - `데이터 프라이버시`: 모델과의 대화 내용이 사용자의 기기에 안전하게 보관됩니다
  - `비용 효율성`: 클라우드 서비스와 달리 사용량에 따른 추가 비용이 발생하지 않습니다
  - `오프라인 접근성`: 인터넷 연결 없이도 자유롭게 모델을 활용할 수 있습니다

Ollama 모델

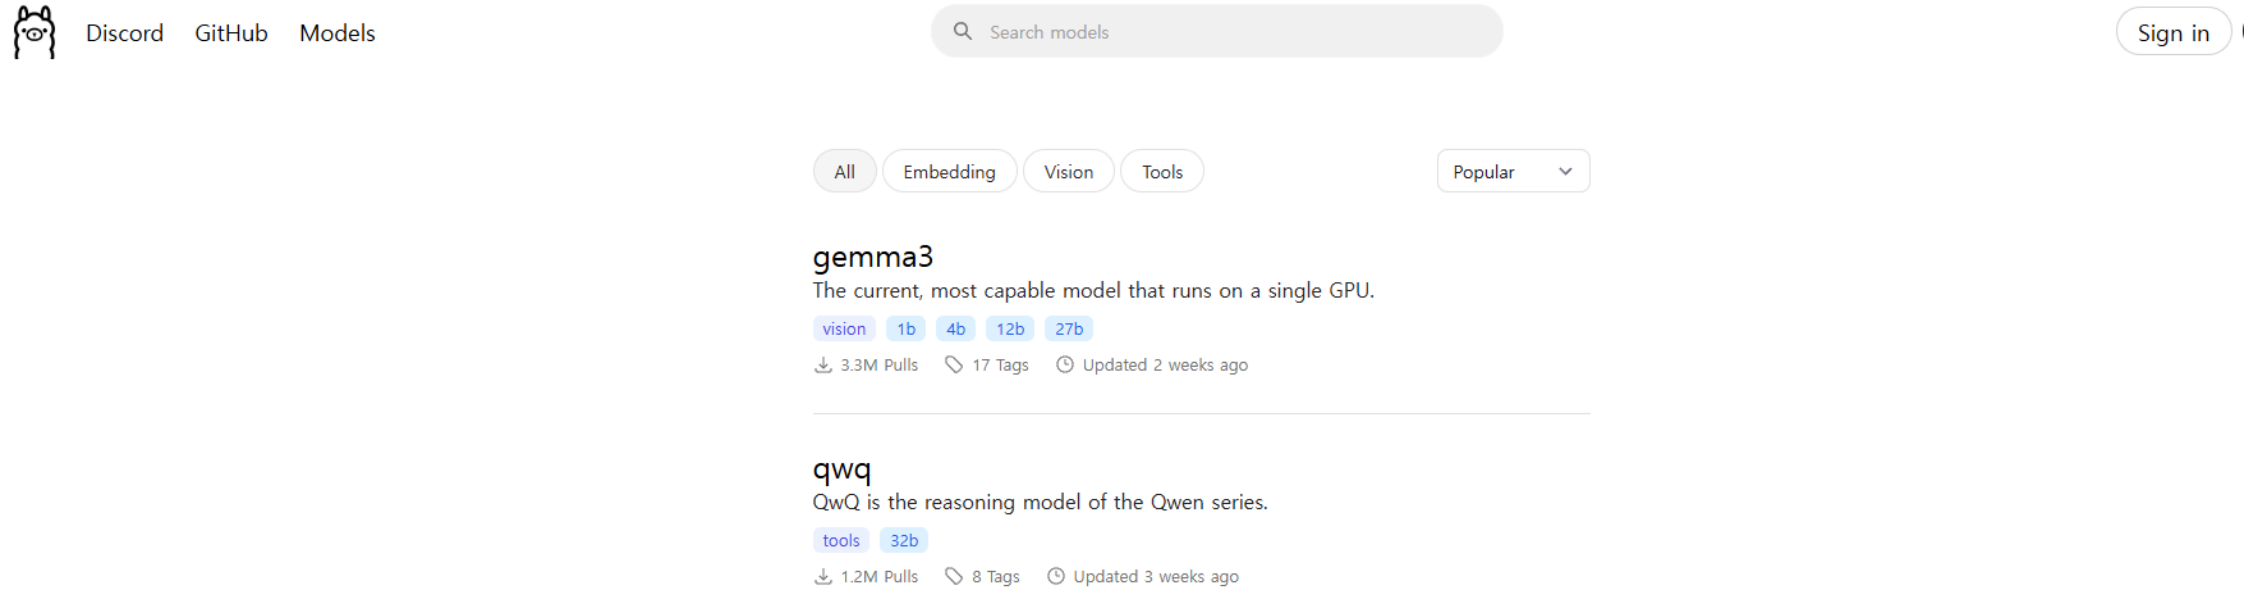
Discord
GitHub
Models
Search models
Sign in
All
Embedding
Vision
Tools
Popular
gemma3
The current, most capable model that runs on a single GPU.
vision
1b
4b
12b
27b
3.3M Pulls
17 Tags
Updated 2 weeks ago
qwq
QwQ is the reasoning model of the Qwen series.
tools
32b
1.2M Pulls
8 Tags
Updated 3 weeks ago

Ollama 설치

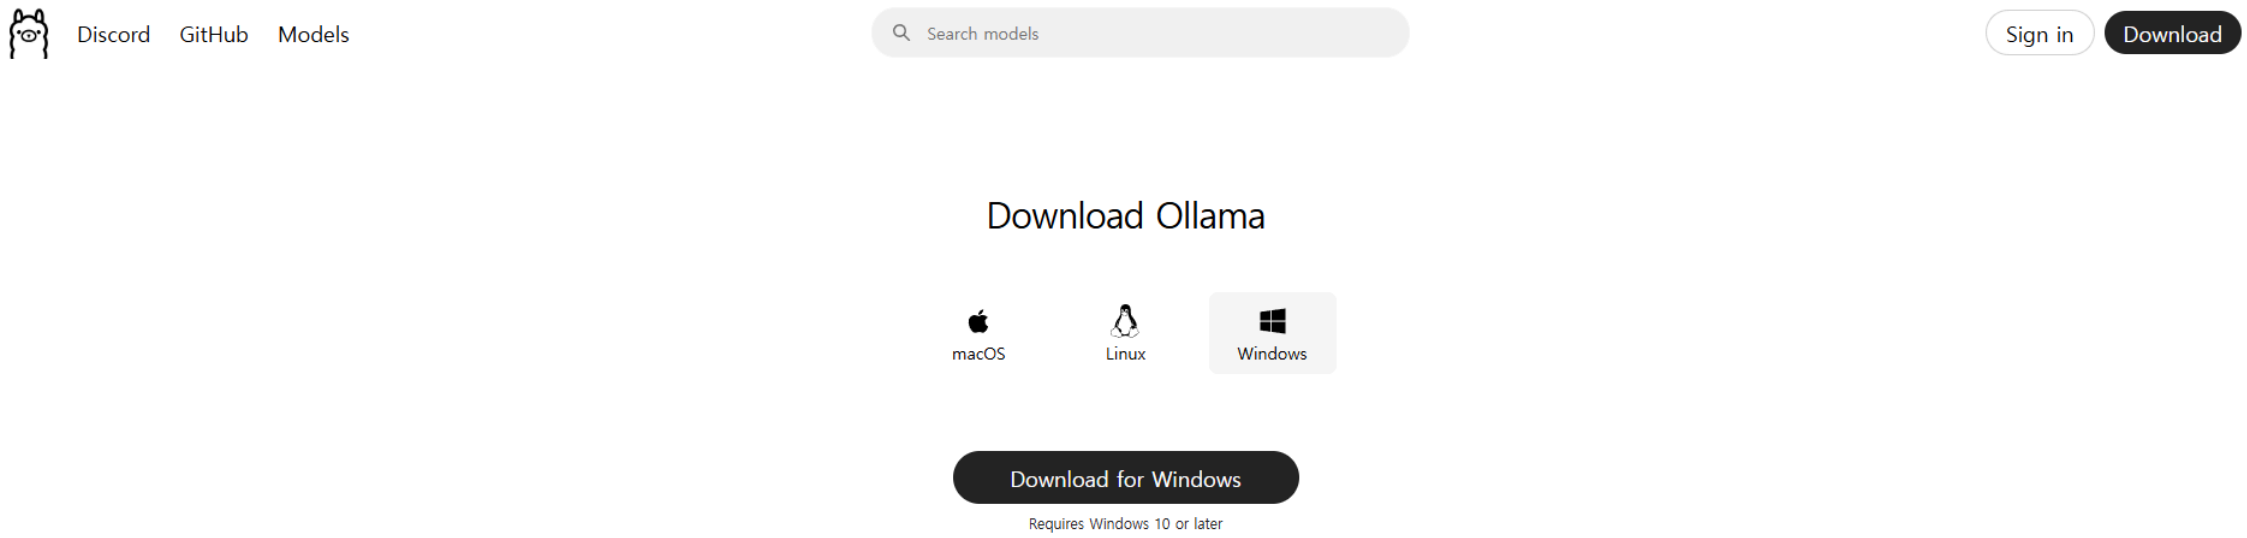
Discord
GitHub
Models
Search models
Sign in
Download
Download Ollama
macOS
Linux
Windows
Download for Windows
Requires Windows 10 or later

Ollam 사용법

ollama 명령어	실행
ollama serve	ollama 시작
ollama pull [model]	[model] 설치
ollama run [model]	[model] 실행
ollama list	모델 리스트 출력
ollama rm [model]	[model] 삭제
/bye	[model] 실행 종료
/?	도움말 출력
/show info	현재 실행 모델 정보 출력
/load [model]	[model] 불러오기
/save [model]	[model] 저장하기

단계1: 모델 다운로드 및 실행

Model library

Ollama supports a list of models available on ollama.com/library

Here are some example models that can be downloaded:

Model	Parameters	Size	Download
Gemma 3	1B	815MB	`ollama run gemma3:1b`
Gemma 3	4B	3.3GB	`ollama run gemma3`
Gemma 3	12B	8.1GB	`ollama run gemma3:12b`

```
ollama run <모델명>:<테그>
```

```
Windows PowerShell
PS C:\Users\good593> ollama run gemma3:1b
pulling manifest
pulling 7cd4618c1faf... 100%  815 MB
pulling e0a42594d802... 100%  358 B
pulling dd084c7d92a3... 100%  8.4 KB
pulling 3116c5225075... 100%  77 B
pulling 120007c81bf8... 100%  492 B
verifying sha256 digest
writing manifest
success
>>> Send a message (/? for help)
```

단계2: 모델 대화 종료

```
/bye
```

```
>>>
>>> 한국의 수도는?
한국의 수도는 서울입니다.

>>> /bye
PS C:\Users\good593>
```

단계3: 다운로드된 모델 조회

```
ollama list
```

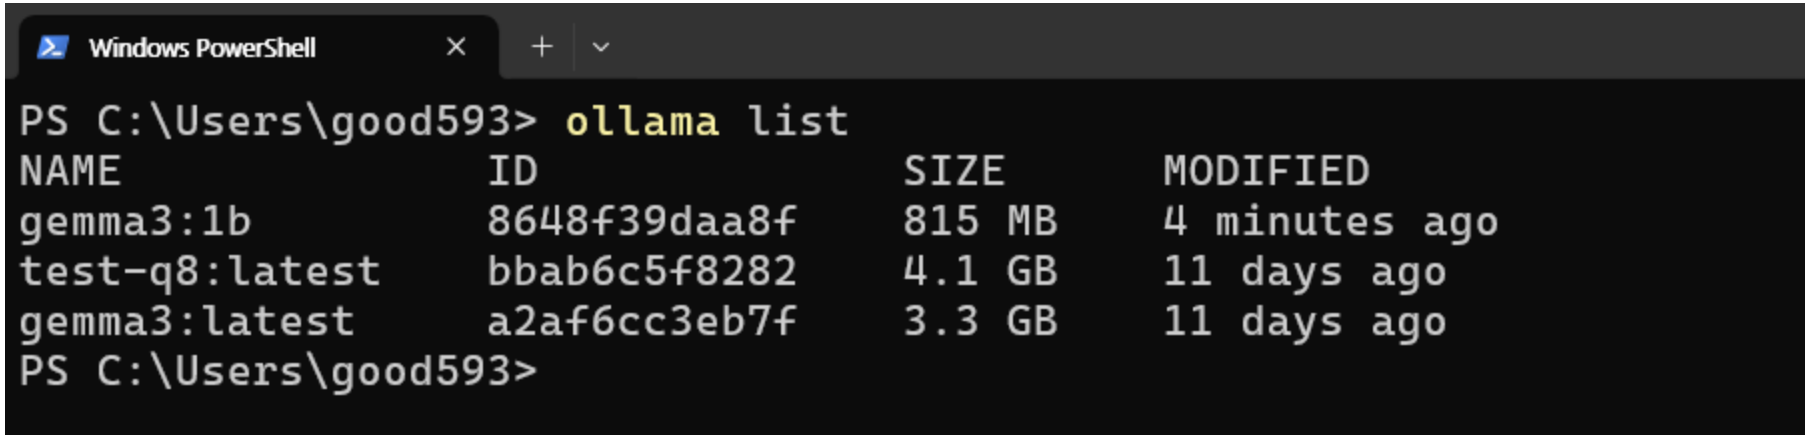

Ollama with Huggingface

```
ollama run hf.co/{username}/{repository}:{quantization}
```

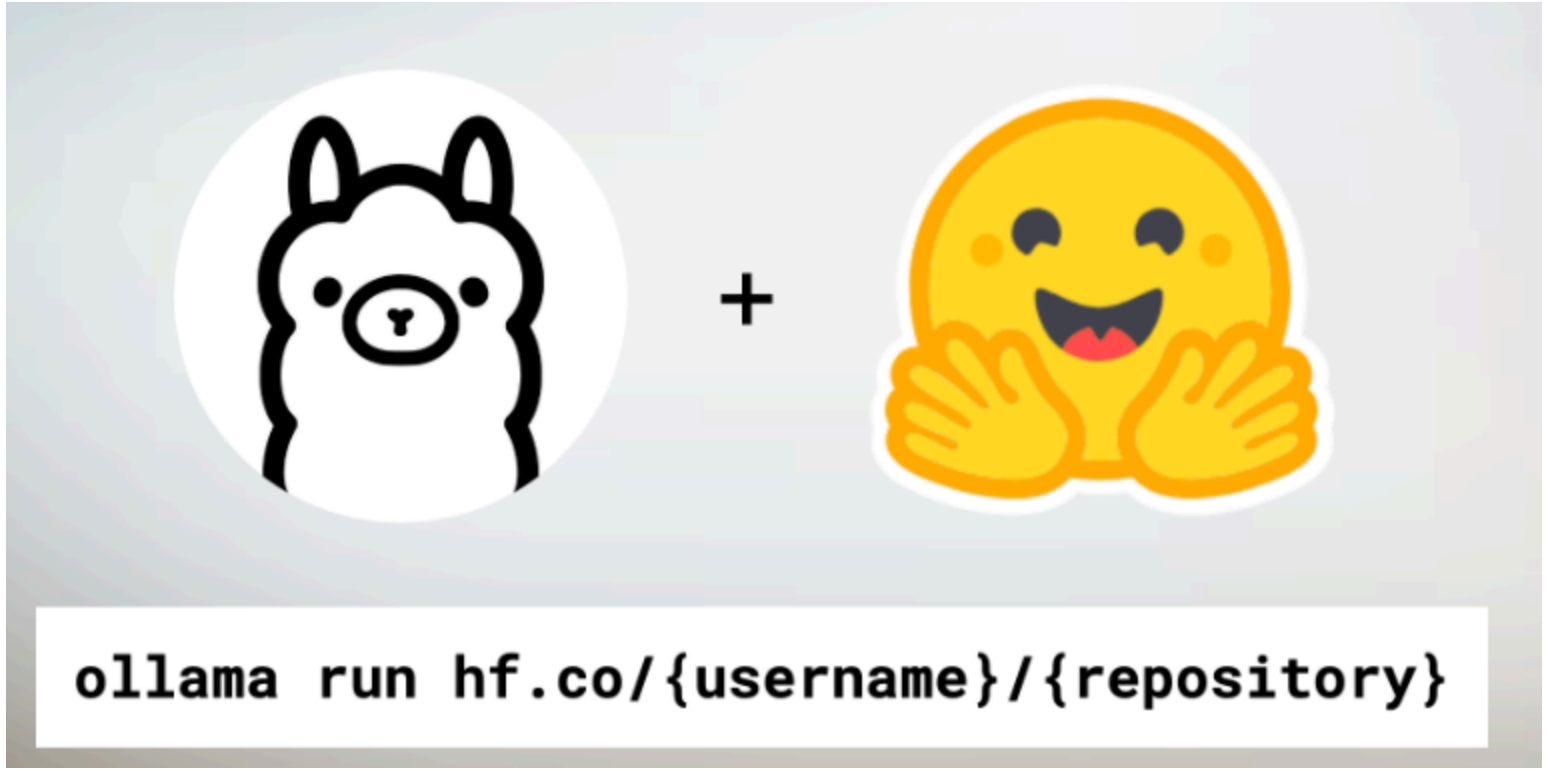

bartowski/Llama-3.2-1B-Instr

huggingface.co/bartowski/Llama-3.2-1B-Instruc...

Relaunch to update

Hugging Face | Search models, datasets, us | Models | Datasets | Spaces | Posts | Docs | Pricing

Log in using Single Sign-On to view activity within the **huggingface** org. Log In

bartowski/**Llama-3.2-1B-Instruct-GGUF** like 31

Text Generation | GGUF | 8 languages | facebook | meta | llama | llama-3 | Inference Endpoints | imatrix | conversational

License: llama3.2

Model card | Files | Community 1 | Deploy | Use this model

Edit model card

Llamacpp imatrix Quantizations of Llama-3.2-1B-Instruct

Using llama.cpp release b3821 for quantization.

Original model: https://huggingface.co/meta-llama/Llama-3.2-1B-Instruct

All quants made using imatrix option with dataset from here

Run them in LM Studio

Downloads last month
42,905

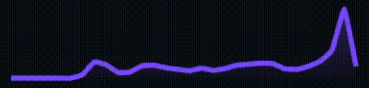

Model size 1.24B params

Architecture llama

GGUF

3-bit						Q3_K_L	Q3_K_XL
4-bit	IQ4_XS	Q4_K_S	Q4_0	Q4_0	Q4_0	Q4_0	Q4_K_M	Q4_K_L

단계1: huggingface에서 gguf 모델 선택

- `unsloth/gemma-3-1b-it-GGUF`

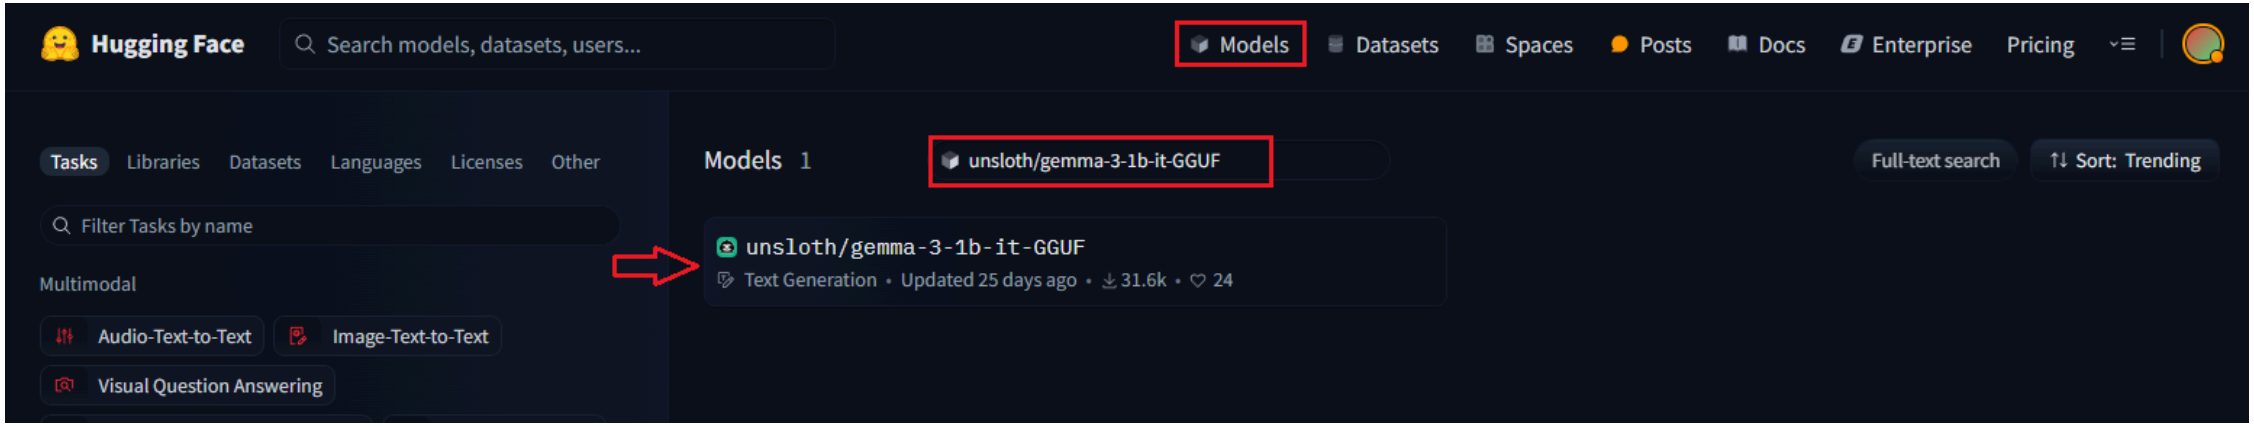

단계2: ollama 선택

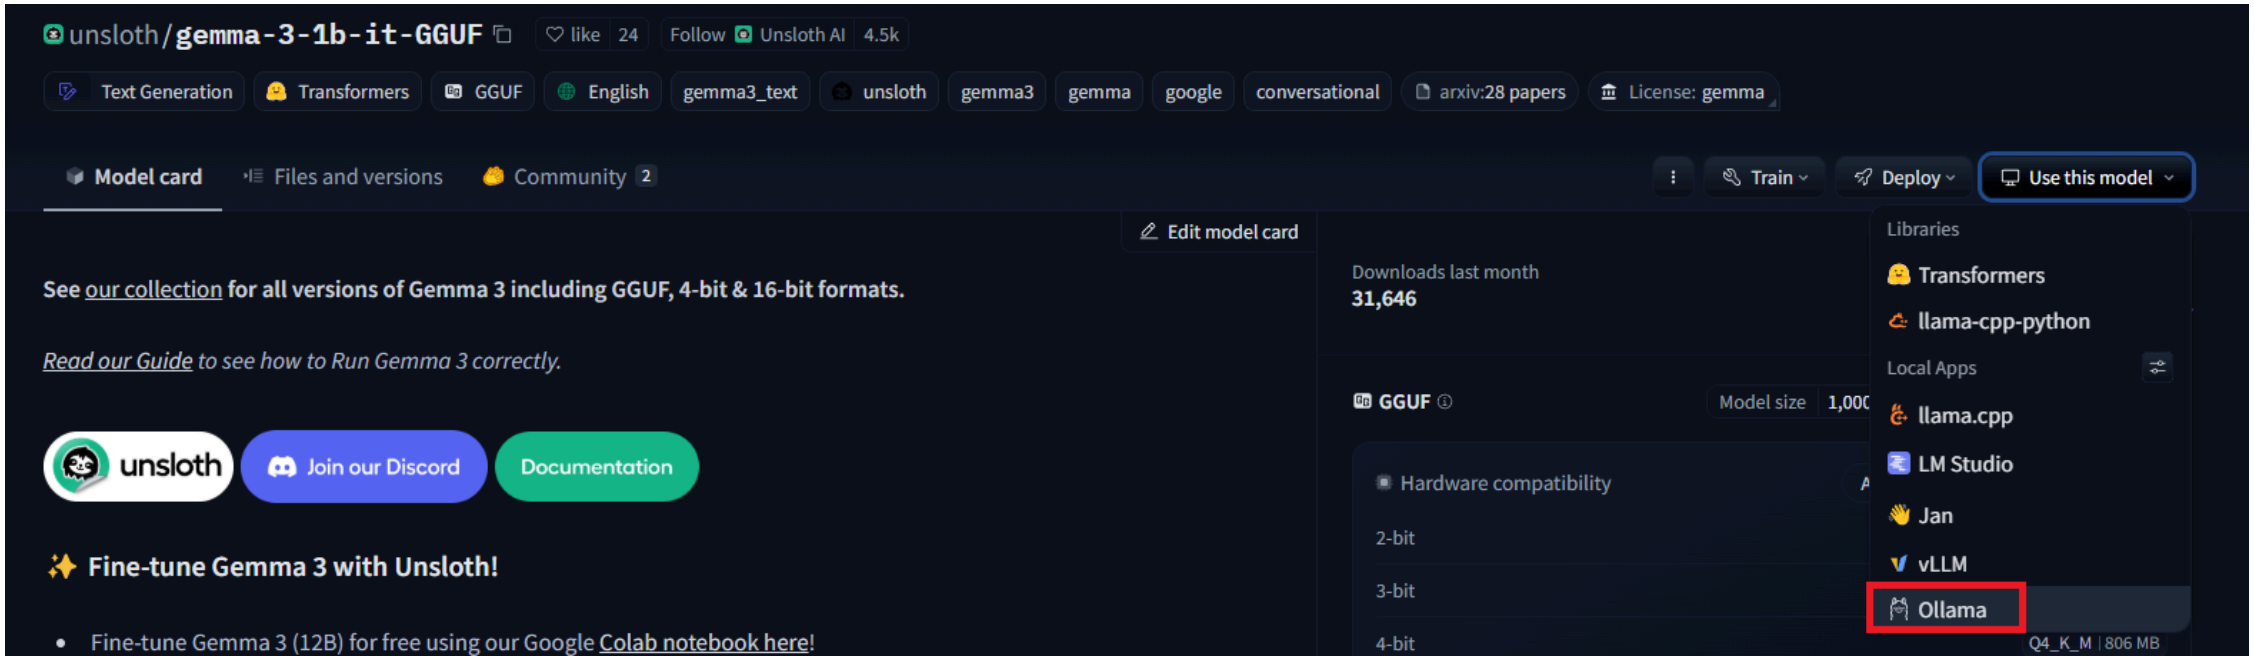

단계3: 명령어 Copy

How to use from
Ollama
ollama run hf.co/unsloth/gemma-3-1b-it-GGUF:Q8_0
Copy
Quick Links
Read the Ollama documentation

단계4: ollama에 다운로드

```
Windows PowerShell
PS C:\Users\good593> ollama run hf.co/unsloth/gemma-3-1b-it-GGUF:Q8_0
pulling manifest
pulling 905f60c0d583... 100%  1.1 GB
pulling e0a42594d802... 100%  358 B
pulling 39bfa1773b74... 100%  201 B
pulling 8056b1ac57ea... 100%  196 B
verifying sha256 digest
writing manifest
success
>>> Send a message (/? for help)
```