Unsloth

- Unsloth는 거대 언어 모델(LLM)의 파인튜닝(Fine-tuning) 속도를 획기적으로 높이고 메모리 사용량을 줄여주는 오픈소스 라이브러리입니다.
- 특히 개인용 GPU를 사용하는 학생이나 연구자들에게 매우 유용한 도구입니다.

Unsloth 장점

일반적으로 LLM을 학습시키려면 엄청난 양의 VRAM(그래픽 메모리)과 시간이 필요합니다. Unsloth는 이를 수학적으로 최적화하여 다음과 같은 이점을 제공합니다.

- `압도적인 속도` : 기존 Hugging Face 방식보다 2배~5배 더 빠른 학습 속도.
- `메모리 효율성` : 메모리 사용량을 70% 이상 절감. (고성능 GPU가 없어도 학습 가능!)
- `손실 없는 정확도` : 속도는 빨라지지만, 모델의 예측 정확도는 전혀 떨어지지 않습니다 (0% Accuracy Loss).
- `초보자 친화적` : 코랩(Google Colab)에서도 단 몇 줄의 코드로 실행 가능합니다.

성능 비교 (Llama-3 8B 모델 기준)

비교 항목	기본 방식 (Hugging Face)	Unsloth 적용 시
학습 시간	10시간	**약 2~3시간**
메모리(VRAM) 점유	16GB 이상	**약 7GB 미만**
정확도	100%	**100% (차이 없음)**

Unsloth LoRA / QLoRA 장점

관점	장점	설명
속도	**학습 속도 매우 빠름**	커스텀 CUDA 커널 + 최적화된 forward/backward
메모리	**VRAM 사용량 최소**	4bit 로딩 + QLoRA 기본 설계
난이도	**설정이 단순함**	YAML 없음, Python 몇 줄로 끝
실험	**빠른 반복 실험 가능**	하이퍼파라미터 변경 부담 낮음
하드웨어	**단일 GPU로 충분**	24GB GPU에서도 7B~13B 가능
통합	**Transformers 호환**	HF Trainer / PEFT 생태계 그대로 사용
저장	**HF Hub 업로드 간단**	`push_to_hub()` 바로 가능
디버깅	**에러 지점 명확**	분산/ZeRO 개념 없음

Docker - Fine Tuning

Dockerfile에 포함된 필수 요소

> RunPod에서 모델 학습 → Hugging Face Hub 저장

기능	라이브러리	상태
모델 로딩/학습	`unsloth`	✅
HF 모델 구조	`transformers`	✅
QLoRA	`bitsandbytes`	✅
Trainer	`trl`, `peft`	✅
Hub 업로드	`transformers` 내부	✅

Docker Hub에 배포하는 명령어

> Docker Image 생성

```
docker build -t <Docker ID>/unsloth-runpod:2025.12.5 .
```

> Docker Container 실행

```
# GPU용
docker run -it --rm --gpus all -p 8080:8080 -v ./workspace:/workspace <Docker ID>/unsloth-runpod:2025.12.5
# CPU용
docker run -it --rm -p 8080:8080 -v ./workspace:/workspace <Docker ID>/unsloth-runpod:2025.12.5
```

> Docker Hub 배포

```
docker push <Docker ID>/unsloth-runpod:2025.12.5
```