sLLM 파인튜닝 모델 평가

파인튜닝 평가, 왜 필요한가?

파인튜닝(Fine-tuning)은 기존 모델을 특정 작업에 맞게 추가 학습시키는 과정입니다.

> **핵심 질문**: "내가 만든 모델이 정말 잘 되고 있는가?"

평가가 없으면:

- 모델이 더 좋아졌는지 나빠졌는지 알 수 없음
- 과적합(Overfitting) 여부를 확인할 수 없음
- 실제 서비스에 써도 될지 판단 불가

평가의 두 가지 큰 축

```
평가 방법
├── 자동 평가 (Automatic Evaluation)  → 빠르고 저렴
└── 인간 평가 (Human Evaluation)     → 느리지만 정확
```

자동 평가 지표 (Automatic Evaluation)

1. 정량 지표 (숫자로 측정)

지표	설명	주로 쓰이는 곳
Perplexity (PPL)	모델이 텍스트를 얼마나 "잘 예측"하는지. 낮을수록 좋음	언어모델 전반
BLEU	정답과 출력의 단어 일치율	번역, 요약
ROUGE	정답과 출력의 겹치는 문장/단어 비율	요약
F1 Score	정밀도(Precision)와 재현율(Recall)의 조화평균	분류, QA
Accuracy	맞춘 비율	분류 태스크

> **주의**: 자동 지표가 높다고 반드시 좋은 모델이 아닙니다.
> BLEU가 높아도 문장이 어색할 수 있어요.

2. LLM-as-a-Judge (AI가 AI를 평가)

강력한 LLM(예: GPT-4, Claude)을 심사자로 써서 출력 품질을 평가하는 방법입니다.

```
[내 파인튜닝 모델 출력] -> [GPT-4 심사] -> 점수 / 피드백
```

장점

- 인간 평가에 가까운 품질
- 대규모 평가 자동화 가능

단점

- 비용 발생
- 심사 LLM의 편향이 들어올 수 있음

인간 평가 (Human Evaluation)

자동 평가만으로는 부족할 때 사람이 직접 평가합니다.

평가 방식

방식	설명
절대 평가	5점 척도로 출력을 직접 점수 매김
상대 평가 (A/B)	두 모델 출력 중 어느 쪽이 더 좋은지 선택
Elo Rating	여러 모델을 대결시켜 순위 산출

평가 기준 예시

- **정확성**: 사실에 맞는가?
- **유창성**: 자연스러운 문장인가?
- **관련성**: 질문에 적합한 답인가?
- **안전성**: 해로운 내용이 없는가?

LLM모델 태스크별 평가 전략

파인튜닝 목적에 따라 평가 방법이 달라집니다.

분류 (Classification)

```
평가 지표: Accuracy, F1 Score, Confusion Matrix
예시: 감성 분석, 스팸 분류
```

생성 (Generation)

```
평가 지표: BLEU, ROUGE, BERTScore, Human Eval
예시: 요약, 번역, 글쓰기
```

질의응답 (QA)

```
평가 지표: Exact Match(EM), F1, Faithfulness
예시: 문서 기반 QA, 챗봇
```

지시 따르기 (Instruction Following)

```
평가 지표: LLM-as-a-Judge, MT-Bench 스타일 평가
예시:
```

벤치마크 평가

> 공개된 표준 테스트셋으로 모델 성능을 비교합니다.

주요 벤치마크 (한국어 포함)

벤치마크	설명	언어
MMLU	다분야 지식 이해 (57개 분야)	영어
HellaSwag	상식 추론	영어
KoBEST	한국어 기초 능력 평가	한국어
KLUE	한국어 언어 이해 벤치마크	한국어
LogiKAT	한국어 논리 추론	한국어

벤치마크: lm-evaluation-harness

- 장점
  - MMLU, HellaSwag 등 60개 이상의 벤치마크가 이미 내장되어 있어서 따로 구현할 필요 없음
  - 커뮤니티가 크고 활발해서 새 벤치마크가 꾸준히 추가됨
  - 재현 가능한 표준화된 평가라 다른 논문/모델과 점수 비교가 쉬움
- 단점
  - 영어 중심 벤치마크가 대부분이라 한국어 평가엔 한계가 있음
  - 큰 모델일수록 평가 시간이 매우 오래 걸림

lm-evaluation-harness vs 다른 평가 모듈

항목	lm-evaluation-harness	Custom Eval (GPT-Judge 등)	HELM	LightEval	단순 예제 평가
목적	표준 성능 비교	실사용 품질 검증	연구용 종합 분석	경량 벤치마크	데모 확인
객관성	높음	낮음	높음	높음	매우 낮음
파인튜닝	중간	매우 높음	중간	중간	매우 낮음
한국어	커스텀 필요	매우 쉬움	어려움	제한적	가능
실무 친화성	높음	매우 높음	낮음	중간	낮음

lm-evaluation-harness + 한국어 특화 평가

구분	lm-evaluation-harness	한국어 특화 평가	이 조합의 의미
평가 대상	일반 LLM 능력	한국어 이해·지시 이행	튜닝 목적이 명확해짐
평가 방식	자동 채점 (MCQ 중심)	정답 기반 + Judge 기반	객관성 + 품질 평가
비교 가능성	매우 높음	낮음	외부 모델과 공정 비교
튜닝 효과 가시성	낮음	매우 높음	파인튜닝 의미를 설명 가능
재현성	매우 높음	중간	논문·강의·Hub에 적합

lm-eval + 한국어 특화 vs lm-eval + DeepEval

평가 관점	lm-eval + 한국어 특화	lm-eval + DeepEval
평가 대상	모델 능력 (언어·지식 중심)	응답 품질 (행동·추론 중심)
한국어 이해력	매우 높음	높음
Fine-tuning 효과	높음	매우 높음
RAG / Tool 사용 적합성	매우 낮음	매우 높음
평가 지표 해석 용이성	매우 높음	중간
커스터마이징 난이도	낮음	중간~높음
외부 비교 가능성	높음	낮음
실무 적합성	중간	매우 높음
난이도	쉬움	중간